



Tecnológico de Monterrey

Actividad 3.2 (Regresión No Lineal)

Sebastián Mejía A01722536

Juan Zamorano A01642396

Carlos Fonseca A01734538

Emily Bueno A01736939

Profesor: Alfredo García Suárez

13 de Abril del 2025

Limpieza de datos

Se aplicaron dos métodos comunes para llenar esos espacios vacíos:

- **Backfill** para datos tipo texto.
- **Median** para datos numéricos.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5865 entries, 0 to 5864
Data columns (total 7 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Administrador          5865 non-null   object
1   Usuario                5865 non-null   object
2   mini juego             5709 non-null   object
3   color presionado       5103 non-null   object
4   dificultad              5865 non-null   object
5   fecha                  5865 non-null   object
6   Juego                  5865 non-null   object
dtypes: object(7)
memory usage: 320.9+ KB
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5865 entries, 0 to 5864
Data columns (total 6 columns):
#   Column                Non-Null Count  Dtype
---  -
0   botón correcto         5103 non-null   float64
1   tiempo de interacción  5103 non-null   float64
2   número de interacción  5103 non-null   float64
3   auto push              5103 non-null   float64
4   tiempo de lección      5688 non-null   float64
5   tiempo de sesión       5259 non-null   float64
dtypes: float64(6)
memory usage: 275.1 KB
```

Como resultado ya no se presentan datos nulos en ninguna columna.

Detección y limpieza de datos extremos (outliers)

- Se analizaron los valores que estaban demasiado altos o bajos en comparación con el resto.
- Se utilizó una técnica llamada “rango intercuartílico” para detectar estos valores extremos.

```
outliers_limpios=data.isnull().sum().sum()  
print(outliers_limpios)
```

0

Frecuencias

Lo que se realizó en este paso, fue sacar las frecuencias de las variables que se nos piden y de igual manera asignamos valores numéricos para identificar de manera más fácil y sencilla las variables que estamos convirtiendo.

Frecuencia administrador

	Administrador	Frecuencia
0	ALEIDA	3260
1	nicolas	440
2	LEONARDO	371
3	DENISSE	302
4	SERGIO ANGEL	243
5	CARLOS ENRIQUE	228
6	Yael DAVID	224
7	AUSTIN	199
8	VALENTIN	163
9	erick	158
10	IKER BENJAMIN	128
11	KYTZIA	98
12	BENJAMIN	51

Se sacó la frecuencia de los administradores en cuestión de las apariciones en nuestro dataset.

Asignacion de numero por administrador

Administrador
2
2
2
2
2
...
1
1
1
1
1

Se le asigna un número al administrador para un manejo más sencillo en la base de datos y podamos identificarlos.

Determinacion de frecuencias de usuarios

	Usuario	Frecuencia
0	LEONARDO	546
1	ALEIDA	487
2	nicolas	440
3	JOSE JAVIER	394
4	LEONARDO	371
5	JESUS ALEJANDRO	356
6	ramiro isai	332
7	ADRIAN	280
8	SERGIO ANGEL	243
9	DENISSE	228
10	CARLOS ENRIQUE	228
11	Yael DAVID	224
12	VALENTIN	163
13	erick	158
14	IKER BENJAMIN	152
15	NICOLAS	128
16	ERICK OSVALDO	126
17	CONCEPCION	103
18	KYTZIA	98
19	AUSTIN	96
20	JOSE IGNACIO TADEO	94
21	JOSE IAN	86
22	ASHLEY	75
23	JOSHUA	74
24	YEREMI YAZMIN	71
25	MA DEL ROSARIO	64
26	BENJAMIN	51
27	INGRID	49
28	RENE	44
29	CARLOS ABEL	39
30	ARLETT	29
31	ESMERALDA	24
32	IRVING	10
33	jesus eduardo	2

Se determina las apariciones de los pacientes en nuestro dataset.

Frecuencia de los juegos

	mini juego	Frecuencia
0	Asteroides	1088
1	Restaurante	888
2	Estrellas	837
3	Gusanos	768
4	sonidos y animales	765
5	animales y colores	563
6	figuras y colores	409
7	partes del cuerpo	329
8	Despegue	197
9	MiniGame_0	8
10	MiniGame_3	5
11	MiniGame_2	5
12	MiniGame_1	3

Se determina la frecuencia de las apariciones de los juegos en el dataset, esto es información muy importante para saber los minijuegos mas jugados.

Asignacion de numeros a los minijuegos

mini juego
9
9
9
9
9
...
2
1
1
1
10

Se le asignan los números a los minijuegos para identificarlos de una manera sencilla.

Frecuencia de los colores presionados

	color presionado	Frecuencia
0	violet	1609
1	green	1455
2	yellow	1425
3	blue	1342
4	red	34

Se determina la frecuencia de los colores presionados en el dataset.

Asignación de números a los colores

color presionado
4
1
2
2
2
...
2
2
2
2
2

Se le asignan los números a los colores presionados para identificarlos de una manera sencilla.

Frecuencia de las dificultades

	dificultad	Frecuencia
0	Episodio 1	2357
1	Episodio 2	1493
2	Episodio 3	1292
3	Episodio 4	723

Se determina la frecuencia de las dificultades en el dataset.

Asignacion de numeros en las dificultades

dificultad
1
1
1
1
1
...
1
3
3
3
3

Se le asignan los números a las dificultades para identificarlos de una manera sencilla.

Cabe recalcar que todos estos pasos, ayudan a realizar el proceso de graficamiento más sencillo.

Relación entre el juego y la frecuencia

	Juego	Frecuencia
0	Astro	3799
1	Cadetes	2066

La tabla muestra que el juego "Astro" fue jugado 3,799 veces, mientras que "Cadetes" se jugó 2,066 veces. Esto te dice claramente cuál es el más usado o preferido.

Analizar las correlaciones lineales simples en el “Heatmap”

El propósito principal de esta sección del código fue identificar qué tan relacionada está la variable “Color Presionado” con otras variables numéricas dentro del conjunto de datos. Para lograr esto, se utilizó una herramienta visual llamada heatmap, que ayuda a representar gráficamente las correlaciones.


Preparación de datos

Para que el análisis de correlación fuera posible, es probable que la columna “Color Presionado”, que originalmente podría contener palabras como “Rojo”, “Verde” o “Azul”, se haya transformado en valores numéricos. Esto permite calcular matemáticamente qué tan relacionadas están esas respuestas con otras variables, como tiempo de reacción, aciertos, errores, etc.

Proponer un modelo no lineal que supere la correlación de el Heatmap.

Al momento de realizar este heatmap, nos dimos cuenta que, el proponer una variable como lo es “Color presionado” para nuestro análisis de regresión no tendría mucho caso, por lo tanto, decidimos cambiar de fundición objetivo la cual pasó a ser “numero de interacción” y “botón correcto” como variable dependiente.

Sin embargo, decidimos documentar todos estos hallazgos en este reporte, ya que lo consideramos importante en el desarrollo de esta actividad.




Modelo no lineal propuesto (función logarítmica)

Se tomaron las variables “número de interacciones” y “botón correcto” para realizar el siguiente modelo de regresión no lineal, con la intención de que nos diera un mayor coeficiente de correlación que en la tabla del heatmap.

Cabe recalcar que el coeficiente de correlación nos funciona para saber que tan dependiente es la “variable dependiente” de la “variable independiente”, este coeficiente de correlación, nos ayuda a explicar el la relación de movimientos entre una variable y otra; a continuación se muestran los resultados obtenidos de este modelo.

En primer lugar, debemos de sacar las predicciones para nuestra variable dependiente para poder realizar el modelo.

Una vez teniendo esto, graficar nuestro modelo. Este modelo lo hicimos usando una función logarítmica.



Por consiguiente, con el modelo propuesto buscamos que nuestro coeficiente de correlación sea mayor que el presentado en el heat map, y como podemos observar es mayor.

```
np.float64(0.3359151183123766)
```

Generar un dataframe por cada “usuario”

Esto permite hacer análisis individuales y personalizados para cada persona, en lugar de trabajar con toda la base de datos al mismo tiempo. Con esto, se puede observar el comportamiento, desempeño y patrones específicos de cada usuario dentro de las sesiones de juego o ejercicios.

```
1 Corr_Factors=ALEIDA.corr()
2 Corr_Factors
```

	Usuario	botón correcto	tiempo de interacción	color presionado	dificultad
Usuario	NaN	NaN	NaN	NaN	NaN
botón correcto	NaN	1.000000	0.031671	-0.012622	-0.308265
tiempo de interacción	NaN	0.031671	1.000000	-0.087922	-0.036661
color presionado	NaN	-0.012622	-0.087922	1.000000	-0.012137
dificultad	NaN	-0.308265	-0.036661	-0.012137	1.000000

```
1 Corr_Factors=ADRIAN.corr()
2 Corr_Factors
```

	Usuario	botón correcto	tiempo de interacción	color presionado	dificultad
Usuario	NaN	NaN	NaN	NaN	NaN
botón correcto	NaN	1.000000	-0.190970	0.027255	-0.061111
tiempo de interacción	NaN	-0.190970	1.000000	-0.029286	0.305132
color presionado	NaN	0.027255	-0.029286	1.000000	0.016560
dificultad	NaN	-0.061111	0.305132	0.016560	1.000000

```
1 Corr_Factors=AUSTIN.corr()
2 Corr_Factors
```

	Usuario	botón correcto	tiempo de interacción	color presionado	dificultad
Usuario	NaN	NaN	NaN	NaN	NaN
botón correcto	NaN	1.000000	0.001153	0.014852	0.077679
tiempo de interacción	NaN	0.001153	1.000000	0.016690	-0.002165
color presionado	NaN	0.014852	0.016690	1.000000	0.034163
dificultad	NaN	0.077679	-0.002165	0.034163	1.000000

```
1 Corr_Factors=ASHLEY.corr()
2 Corr_Factors
```

	Usuario	botón correcto	tiempo de interacción	color presionado	dificultad
Usuario	NaN	NaN	NaN	NaN	NaN
botón correcto	NaN	1.000000	-0.057895	-0.098137	-0.096060
tiempo de interacción	NaN	-0.057895	1.000000	0.014263	0.211614
color presionado	NaN	-0.098137	0.014263	1.000000	-0.027037
dificultad	NaN	-0.096060	0.211614	-0.027037	1.000000

```
1 Corr_Factors=ARLETT.corr()
2 Corr_Factors
```

	Usuario	botón correcto	tiempo de interacción	color presionado	dificultad
Usuario	NaN	NaN	NaN	NaN	NaN
botón correcto	NaN	1.000000	-0.359681	0.258518	-0.320232
tiempo de interacción	NaN	-0.359681	1.000000	-0.651315	0.358348
color presionado	NaN	0.258518	-0.651315	1.000000	-0.534216
dificultad	NaN	-0.320232	0.358348	-0.534216	1.000000

Transformación inicial de columnas

Antes de separar los datos, se realizaron algunas modificaciones para preparar la información:

- Se reemplazaron los nombres de los administradores por números del 1 al 13, con el fin de facilitar el análisis y simplificar el uso de herramientas estadísticas.
- Se hizo algo similar con la columna "Usuario", transformando los nombres por identificadores numéricos.

Se filtraron los datos de la tabla principal y se guardaron únicamente aquellos que correspondían a un usuario específico, como ALEIDA o ADRIAN. Cada uno de estos nuevos DataFrames contiene únicamente las interacciones, respuestas y métricas asociadas a esa persona.

Antes de crear estos nuevos DataFrames, se eliminaron varias columnas que no eran necesarias para este análisis. Esto se hace para trabajar solo con la información que realmente se quiere estudiar, y para que los modelos no se contaminen con variables que ya no son útiles en esta etapa.

Importancia de este procedimiento

Separar los datos por usuario es útil por varias razones:

- Permite hacer comparaciones entre usuarios.
- Facilita el análisis, como predecir su rendimiento o comportamiento individual.

Al crear un DataFrame por usuario, se obtiene una visión clara y detallada de cada individuo. Esto abre la puerta a análisis más avanzados como regresiones individuales, predicciones específicas o gráficas por usuario. Es un enfoque práctico y muy útil cuando se trabaja con información sensible o centrada en el comportamiento humano.

	botón correcto	tiempo de interacción	número de interacción	tiempo de lección	tiempo de sesión	Administrador	Usuario	mini juego	color presionado	dificultad	Juego
0	1.0	5.399169	1.0	0.000000	0.000000	2	NaN	9	4	1	NaN
1	0.0	1.283400	2.0	0.000000	0.000000	2	NaN	9	1	1	NaN
2	1.0	2.700226	3.0	0.000000	0.000000	2	NaN	9	2	1	NaN
3	0.0	3.050262	4.0	0.000000	0.000000	2	NaN	9	2	1	NaN
4	0.0	4.750256	5.0	0.000000	0.000000	2	NaN	9	2	1	NaN
...	...	...	...	...	...	...	...	...	...	...	...
5860	0.5	10.000000	13.3	6.300000	332.240000	1	NaN	2	2	1	NaN
5861	0.0	2.135419	1.0	0.000000	0.000000	1	NaN	1	2	3	NaN
5862	0.5	10.000000	13.3	2.271806	12.400000	1	NaN	1	2	3	NaN
5863	0.5	10.000000	13.3	6.300000	6.478299	1	NaN	1	2	3	NaN
5864	0.5	10.000000	13.3	6.300000	12.400000	1	NaN	10	2	3	NaN

Generar el heatmap de cada usuario y con las siguientes variables como objetivo: “tiempo de interacción”, “botón correcto” “color presionado” y “dificultad”.

Esta sección del código tiene como finalidad generar un heatmap de correlaciones para cada usuario individualmente. De esta manera, se pueden observar los patrones de comportamiento y las relaciones entre variables dentro de los datos de cada usuario, sin que se mezclen con los de otros. Esto es clave cuando se quiere analizar el rendimiento o las preferencias de forma personalizada.

Esto nos permitió descomponer el comportamiento de cada persona y observar sus patrones únicos de correlación entre variables. Este tipo de visualización no solo

hace que los datos sean más comprensibles, sino que también apoya la toma de decisiones basadas en datos reales y personalizados.

En este punto, primeramente se tuvo que hacer un “drop” de las columnas que no se fueran a tomar en cuenta para el análisis



```
1 data=data.drop(["fecha"],axis=1)
2 data=data.drop(["auto push"],axis=1)
3 data=data.drop(["número de interacción"],axis=1)
4 data=data.drop(["tiempo de lección"],axis=1)
5 data=data.drop(["tiempo de sesión"],axis=1)
6 data=data.drop(["Administrador"],axis=1)
7 data=data.drop(["mini juego"],axis=1)
8 data=data.drop(["Juego"],axis=1)
```

Asignamos variables para que cada usuario acumule sus propios datos

```
1 aleida = 1
2 adrian = 2
3 austin = 3
4 ashley = 4
5 arlett = 5
6 ALEIDA = data[data["Usuario"] == aleida]
7 ADRIAN = data[data["Usuario"] == adrian]
8 AUSTIN = data[data["Usuario"] == austin]
9 ASHLEY = data[data["Usuario"] == ashley]
10 ARLETT = data[data["Usuario"] == arlett]
```


Los heatmaps generados para cada uno con las mismas correlaciones obtenidas al generar los dataframes previos

ALEIDA




ADRIAN


AUSTIN



ARLETT



ASHLEY



Proponer un modelo de regresión no lineal que supere las correlaciones obtenidas en el heatmap de cada usuario.

El propósito principal de este apartado es crear un modelo matemático no lineal que explique mejor la relación entre ciertas variables que las simples correlaciones vistas en los heatmaps. Por lo tanto se busca predecir un comportamiento con mayor precisión utilizando un modelo más complejo y ajustado a la forma de los datos.

Se propuso una regresión no lineal logarítmica, definida mediante una función logarítmica.


A diferencia del heatmap, que solo muestra correlaciones generales, este modelo:

- Hace predicciones concretas sobre el rendimiento.

- Puede ser usado para anticipar resultados futuros.
- Ayuda a ver cómo el aprendizaje o la práctica influye en el desempeño del usuario (por ejemplo, si mejora con el tiempo o no).

Esta técnica o modelo permite interpretar el comportamiento del usuario de manera más precisa, lo cual es muy útil en entornos donde se busca personalizar la experiencia o evaluar el progre

Gráficas:



Conclusiones

Este análisis permitió comprender mejor el comportamiento individual de los usuarios y la relación entre distintas variables dentro de la plataforma. Gracias al uso de herramientas visuales y modelos matemáticos, se identificaron patrones importantes y se lograron predicciones más precisas. Aunque aún hay espacio para mejorar los resultados, el trabajo realizado demuestra que con una base de datos bien preparada se pueden obtener conclusiones útiles para tomar decisiones más acertadas.